

X10 Autonomous Content Factory

Архитектура автономной редакционной системы: AI-конвейер из 8 агентов, один Content Object → три канала вывода (Mini App · Web · Quarterly PDF), оркестрационная админ-консоль для редакторов, режим полного автопилота с post-hoc аудитом.

8

AI-агентов в pipeline
(было 6 в v1.0)

3

канала вывода:
Mini App · Web · PDF

0

обязательных human gate
в категории low-risk

20%

ежедневная выборка
post-hoc аудита

Содержание

01	Принципы автономности и три развилки	р. 02	09	«Пульт X10» — отдельный продукт	р. 10
02	System Context — C4 уровень 1	р. 03	10	Admin Console — оркестрация фабрики	р. 11
03	Containers — C4 уровень 2	р. 04	11	Data Layer — ER + sync engine	р. 12
04	Ingestion Layer — источники, дедуп, 152-ФЗ	р. 05	12	Observability + Daily Audit Loop	р. 13
05	AI Pipeline v2 · 8 агентов	р. 06	13	Cost Model v2.0 + матрица рисков	р. 14
06	Confidence thresholds + kill switches	р. 07	14	Phasing F2 → F7	р. 15
07	Content Object — single source of truth	р. 08	15	Решения до старта F2 + открытые вопросы	р. 16
08	Multi-Channel Renderers	р. 09	—	colophon, версия документа	v2.0

ЗАМЕТКА АРХИТЕКТОРА · ОТ ПОЛЬЗОВАТЕЛЬСКИХ РЕШЕНИЙ К ДОКУМЕНТУ

Этот спек написан после трёх фиксированных решений: (1) агрегация только публичных ТГ-каналов клампов через Bot API · (2) полный автопилот с post-hoc аудитом раз в день · (3) PDF только как ежеквартальный премиум-журнал. Каждое решение сужает архитектуру и снимает целые ветки рисков — поэтому документ короче и плотнее, чем мог бы быть в режиме «все варианты сразу».

Серия v2.0 продолжает серию v1.0. Этот спек — её F1 из семи запланированных фаз. F2 детализирует Ingestion, F3 — AI pipeline, F4 — рендереры, F5 — админку, F6 — «Пульт», F7 — обновлённый Implementation Roadmap. Каждая фаза = одна сессия = один PDF в этой же дизайн-системе.

01 · ПРИНЦИПЫ АВТОНОМНОСТИ

Что изменилось vs v1.0

v1.0 описывал AI как ассистента редактора. v2.0 описывает редактора как оператора AI-фабрики. Это не количественный, а качественный сдвиг ответственности.

Параметр	v1.0 — Tech Roadmap	v2.0 — Autonomous Factory
Агенты	6: Draft → Numbers → FactCheck → ToV → Brevity → Audio	8: + SourceCurator → 6 v1 → + Distribution + AuditAgent
Human gate	Обязательный перед publish	Опциональный. Срабатывает только на пороги confidence
Источники	Редактор приносит тему	Автокурация из RSS + 30+ публичных ТГ-каналов клампов
Каналы вывода	Mini App + email + кварталный PDF	Mini App + Web Landing + кварталный PDF (+ опц. newsletter)
Аудит	Пер-статейный pre-publish review	Post-hoc на 20% случайной выборке раз в день
AI-бюджет	~ \$50/мес pipeline · \$330 на пике	~ \$250–400/мес pipeline · \$600 на пике с «Пульсом»

Три зафиксированных решения

РАЗВИЛКА · 01

Только публичные ТГ-каналы

Через **Telegram Bot API**, без MTPROTO и opt-in флоу.
Согласие = факт публикации в публичный канал клампа.
Юридически чисто по 152-ФЗ, но охват ограничен тем, что админы сами вынесли в публичное поле.

РАЗВИЛКА · 02

Полный автопилот + post-hoc

Публикация без human gate в категориях low-risk (агрегация, курсы, дайджесты, «Пульс»).

AuditAgent раз в день берёт 20% случайной выборки и пересматривает. Если > 2% ошибок — автопауза категории.

РАЗВИЛКА · 03

PDF только ежеквартально

Ежедневная авто-вёрстка PDF **отменена**. Один сценарий: ежеквартальный premium-журнал как сувенир для форумов КОД X10. Это разгружает рендереры на одну позицию и упрощает F4.

Пять принципов автономности

01 REVERSIBILITY

Любая публикация откатывается за < 60 секунд. Все артефакты пайплайна сохраняются: source URL, draft, после-агента-N, итог.

02 CONFIDENCE OVER CONSENSUS

Решение публиковать принимается на основе численного confidence-score от агентов, не на «договорённости» между ними.

03 KILL SWITCH ON EVERY LEVEL

Owner и Editor-in-Chief могут остановить любой агент, любую категорию, всю фабрику в один клик. State сохраняется.

04 ONE CONTENT OBJECT

Mini App, Web Landing и Quarterly PDF читают одну сущность из БД. Никакого «дубль текста для PDF».

05 OBSERVABLE BY DEFAULT

Каждый прогон каждого агента: вход, выход, latency, cost, confidence — логируется в OpenTelemetry. Без логов агент не запускается. Это базовое требование для post-hoc аудита.

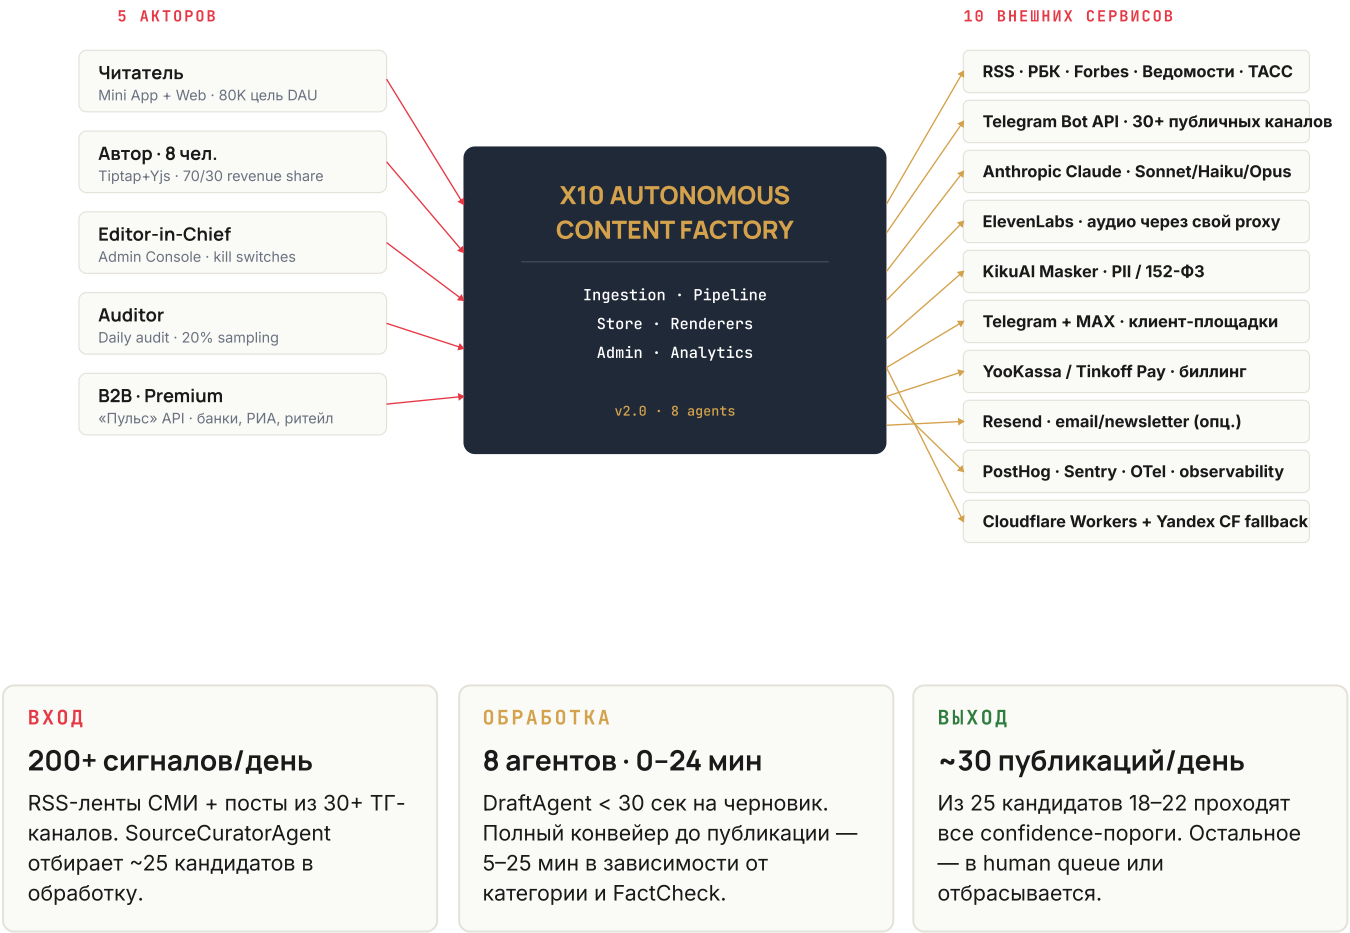
ГЛАВНЫЙ РИСК АВТОПИЛОТА · СФОРМУЛИРОВАН ЗАРАНЕЕ

Без human gate любая ошибка AuditAgent масштабируется до объёма публикации **между аудитами**. Если автопилот идёт со скоростью 30 заметок/день и аудит ежедневный, окно повреждения = **30 публикаций**. Решение принято осознанно — это допустимый риск для категории low-risk, но **недопустимый** для авторских колонок, политических разборов и Disclosure-of-Interest материалов. Эти категории — всегда

02 · C4 LEVEL 1 · SYSTEM CONTEXT

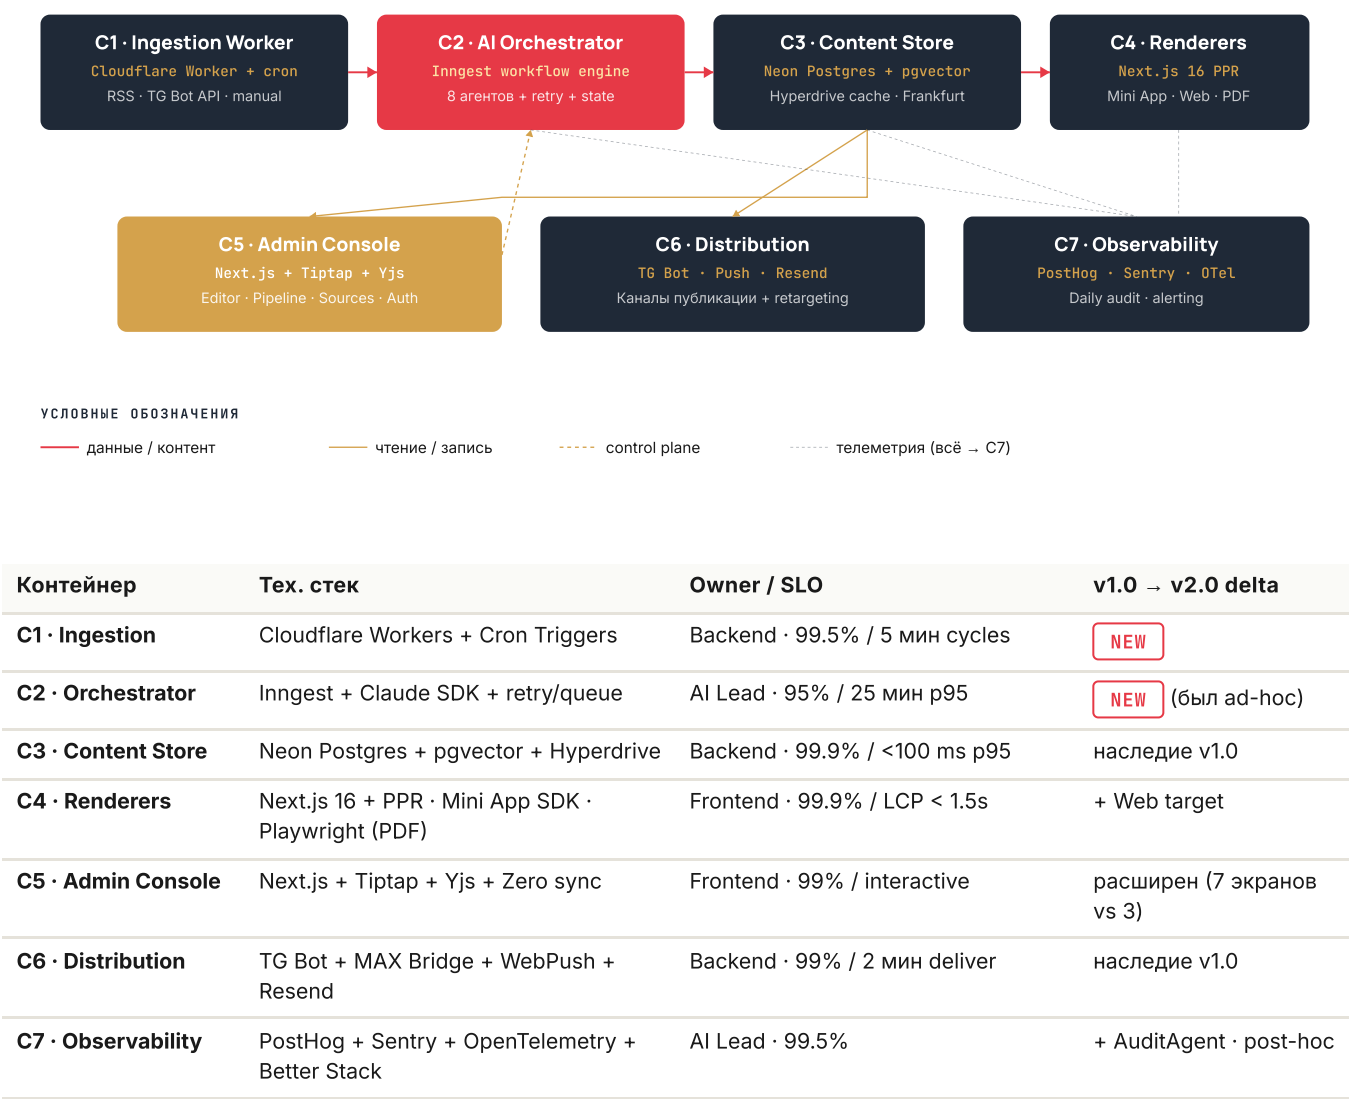
Кто и что обращается к фабрике

X10 Autonomous Factory как единая система с пятью группами акторов слева и десятью внешними сервисами справа. Внутри — единый Content Engine, который обслуживает все потоки.



Семь контейнеров внутри фабрики

Декомпозиция X10 Factory на исполняемые единицы. Каждый контейнер деплоится и масштабируется независимо, имеет свой owner и runbook. Технологический выбор — наследие Tech Roadmap v1.0 + три нововведения для v2.0.



Источники, расписания, дедупликация

Три типа источников с разными механизмами сбора, общим pipeline дедупликации и обязательным шагом 152-ФЗ-маскировки перед передачей в AI. Цикл — каждые 5 минут для horizons-источников, каждые 30 минут для агрегации ТГ-каналов.

Три типа источников

A · RSS-ЛЕНТЫ 7 деловых СМИ РБК, Forbes Russia, Ведомости, Коммерсант, ТАСС, Интерфакс, vc.ru. Pull каждые 5 мин. Если RSS закрыт — fallback на feedburner-зеркала или скрейпинг с rate-limit. Объём/день ~ 150 Tex rss-parser + Cheerio	B · ТГ ПУБЛИЧНЫЕ 30+ каналов клампов Через Telegram Bot API: бот добавлен как читатель в публичные каналы кламперов. Получает все посты как channel_post events. Pull каждые 30 мин. Объём/день ~ 50 Tex grammY · TG webhook	C · РУЧНОЙ ВВОД Редакция и авторы Через Admin Console: автор создаёт черновик в Tiptap, помечает «в pipeline» или «в работу». Pipeline-режим прогоняет через тех же 8 агентов, но финальная публикация — за автором. Объём/день ~ 15 Tex Tiptap + Yjs
---	--	--

Pipeline дедупликации и нормализации




DEDUPE — ДВУХСЛОЙНАЯ Слой 1: SimHash по содержимому — отсекает 80% дублей за < 1 мс. Слой 2: pgvector embedding (Voyage AI или text-embedding-3-small) — cosine > 0.85 = дубль. Защита от перефразированных пересказов одной новости в 3+ каналах.	PII MASK — ОБЯЗАТЕЛЬНЫЙ ШАГ KikuAI Masker заменяет ФИО, телефоны, email, ИНН, паспортные данные на стабильные плейсхолдеры ([ЧЕЛОВЕК_001]) до отправки в Claude. После публикации — обратная подстановка. Соответствие 152-ФЗ при трансграничной передаче.
--	--

ОТКАЗОУСТОЙЧИВОСТЬ INGESTION · ЧТО ЕСЛИ RSS ИЛИ TG ВРЕМЕННО НЕДОСТУПНЫ

Cloudflare Worker делает retry с экспоненциальным backoff (1 с → 4 с → 16 с → 64 с). После 4 неудач — алерт в **C7 Observability**, источник помечается как degraded. Pipeline продолжает работать на остальных источниках. Если из строя выходит TG Bot API целиком — это уведомление в админку, но **не остановка** фабрики: RSS+manual покрывают 80% inflow.

Конвейер: от 200 сигналов к ~30 публикациям

Расширение v1.0 с 6 до 8 агентов: добавляются **SourceCuratorAgent** в начале (отбор из шума) и **DistributionAgent** в конце (куда какой формат). AuditAgent работает отдельным asynchronous loop раз в день — он не блокирует pipeline.



Новые агенты — детали

01 SOURCECURATOR · HAIKU 4.5 Вход: 200 сигналов/день из C1. Выход: ~25 кандидатов с topic-метками. Логика: отсеивает рекламу, нерелевантное, дубли с уже опубликованным. Промпт включает: ToV v1.0, anti-goals, последние 100 опубликованных тем для anti-repetition. Cost: 200 × \$0.001 = \$0.20/день.	08 DISTRIBUTION · HAIKU 4.5 Вход: готовый Content Object. Выход: решение по каналам и формату. Логика: Mini App всегда. Web — если > 400 слов или > 1 числовая ссылка. Push — если topic в подписке у пользователя. Email-digest — раз в день агрегатом. Cost: 30 × \$0.001 = \$0.03/день.
---	---

Решение «публиковать или нет»

Каждый агент возвращает **confidence** от 0 до 1, а оркестратор сверяет с порогами по категории контента. Категории определяют не только threshold, но и discretion агента: **blocking** (упасть в human queue), **soft** (publish с alert), **auto** (publish без флага).

Карта категорий и порогов

Категория	Numbers	FactCheck	ToV	Brevity	Discretion · если ниже порога	
Курсы / макро / агрегация low-risk · 40% объёма	0.85	0.80	0.75	0.70	AUTO	publish без alert
«Пулс X10» / региональное low-risk · 20% объёма	0.85	0.80	0.75	0.70	AUTO	publish без alert
Дайджесты + разборы новостей medium · 25% объёма	0.90	0.85	0.80	0.75	SOFT	publish с флагом для Auditor
Аналитика + лонгриды medium · 10% объёма	0.92	0.88	0.80	0.75	SOFT	publish с флагом для Auditor
Политика, налоги, регуляторика high · 4% объёма	0.95	0.92	0.85	0.80	BLOCKING	всегда в human queue
Авторские колонки high · 1% объёма	—	—	0.85	—	BLOCKING	всегда автор + редактор

Confidence считается так: для Numbers — % чисел, которые удалось верифицировать с источником. Для FactCheck — взвешенный score по числу проверенных утверждений. Для ToV — отсутствие слов из чёрного списка + структура 6 блоков Smart Brevity. Для Brevity — длина и плотность.

Kill switches — уровни и владельцы

ЧТО МОЖНО ОСТАНОВИТЬ		УРОВНИ ДОСТУПА	
Один агент по имени	→ pipeline пропускает	Owner	все switches · audit-логи · billing
Один источник	→ ingestion skip	Editor-in-Chief	все switches · кроме billing
Одна категория	→ в human queue	Editor	category + source switches · human queue
Один канал вывода	→ publish paused	Author	свои черновики · своя категория
Вся фабрика	→ emergency stop	Auditor	read-only · post-hoc audit + reporting
		Все действия по switches пишутся в immutable audit-лог с метками времени и оператором. Восстановление прав через 2FA.	

ПОЧЕМУ ПОРОГИ ИМЕННО ТАКИЕ · ОТКАЛИБРОВАНЫ ПО v1.0 REWRITES

В Rewrites v1.0 при ручном переделе 4 статей нашлась **1 выдуманная цитата** Уоррена Баффета — это 1 ошибка на 4 материала, или **25% false-positive rate** у человека-журналиста до AI. На пилоте F3 первые 100 статей пройдут pipeline в shadow-режиме (без публикации) — реальные пороги откалибруются по результату. Текущие — стартовая оценка по best-practice newsroom AI (NYT Print, Bloomberg). **Все цифры в таблице пересматриваются после первой недели live-эксплуатации.**

07 · SINGLE SOURCE OF TRUTH

Один Content Object — все каналы

Сущность `content_item` — единственный источник правды. Mini App, Web Landing и квартальный PDF читают её через разные view-проекции, но никогда не дублируют поля. Это спасает от «фрагментации правды», когда заголовок в TG отличается от заголовка в Web.

JSON-schema (минимально необходимая)

```
{
  "id": "ci_01HX...",           // ULID
  "version": 7,                 // инкремент при каждом change
  "status": "published",        // draft|in_pipeline|human_queue|published|archived
  "category": "digest_market",  // см. карту категорий стр. 07
  "locale": "ru-RU",

  "core": {                     // общее для всех каналов
    "slug": "rubl-77-doklad-cbr-iyun",
    "title": "Рубль 77: разбор июньского доклада ЦБ",
    "dek": "Что меняется для бизнеса в горизонте 3 месяцев",
    "body_md": "...",           // MDX, Smart Brevity 6 блоков
    "tags": ["налоги", "ЦБ", "рубль"],
    "hero_image": "img_...",
    "author_id": "usr_romanov",
    "published_at": "2026-06-04T07:00:00Z"
  },

  "pipeline": {                 // артефакты прогонов агентов
    "source_url": "https://cbr.ru/...",
    "source_type": "rss",
    "runs": [
      { "agent": "SourceCurator", "confidence": 0.91, "ms": 820, "cost_usd": 0.0008 },
      { "agent": "Draft", "confidence": 0.88, "ms": 3400, "cost_usd": 0.012 },
      { "agent": "Numbers", "confidence": 0.96, "ms": 2100, "cost_usd": 0.009 },
      // ...все агенты до Distribution
    ],
    "discretion": "auto"        // auto|soft|blocking
  },

  "channels": {                 // per-channel overrides
    "miniapp": { "enabled": true, "push": true, "audio_url": "..." },
    "web": { "enabled": true, "seo_title": "...", "og_image": "..." },
    "pdf_q": { "enabled": false, "section": null }, // квартальный отбор отдельно
    "newsletter": { "enabled": true, "slot": "morning_digest" }
  },

  "embedding": "[vec...]",      // pgvector · для дедупа + RAG
  "audit": {
    "sampled_at": null,         // заполняется AuditAgent
    "verdict": null,            // "ok" | "issue:{type}"
    "notes": ""
  }
}
```

ВЕРСИОНИРОВАНИЕ

Каждое сохранение инкрементит `version`. История хранится в `content_revisions` отдельной таблицей. Откат за 1 клик.

EMBEDDING

`pgvector` размерность 1536. Используется в `SourceCuratorAgent` (дедуп) и в Mini App (related articles, search).

AUDIT ПОЛЯ

Заполняются `AuditAgent` раз в день. Если `verdict` $\neq$ `ok` — статья помечается в админке красным флагом + alert.

Multi-Channel Renderers

Один Content Object — три проекции. Все три читают одну и ту же сущность из Neon, но каждый рендерер применяет свою трансформацию: Mini App жмёт в мобильную карточку, Web разворачивает в SEO-страницу, ежеквартальный PDF собирает кураторскую вёрстку.

Карта рендереров

R1 · TELEGRAM MINI APP + MAX

Мобильная карточка

Основной канал · 60% DAU

Фреймворк	Next.js 16 PPR
SDK	TG Mini App 7.x + MAX Bridge
LCP target	< 1.5 c
Полей из CO	title, dek, body_mdx, audio
Sync	Zero (Rocicorp) для чатов
Auth	Telegram initData

5 экранов из прототипа сессии 1: Лента + дайджест, Лонгрид, НалогИ, Сообщество, Профиль. Push 7:00 + 19:00.

R2 · WEB LANDING

SEO + distribution

Открытое окно · 40% всех visits

Фреймворк	Next.js 16 PPR (тот же)
URL	x10daily.ru/{slug}
LCP target	< 1.2 c
SEO	JSON-LD Article + Person + Org
OG/share	опц. сгенерированные карточки
Paywall	3 free/мес → Premium

85% трафика конкурентов идёт из поиска (vc.ru). Web — это **новый канал ввода** воронки, которого не было в v1.0.

R3 · QUARTERLY PDF

Премиум-сувенир

4 раза в год · сувенир форумов

Стек	HTML → Playwright
Триггер	ручной + cron кварталнo
Объём	40–60 стр. А4
Отбор	top-20 + кураторские блоки
Тираж	1000–3000 экз. (форумы)
Дизайн	финализирован в v1.0

Используется тот же pipeline, что создавал этот документ: HTML + CSS → headless Chromium → PDF. Никаких InDesign.

Опциональный R4 · Newsletter (моё предложение из прошлого ответа)

EMAIL + PUSH ДАЙДЖЕСТ	Драйвер	+15-25% DAU (Morning Brew)
Утренний 7:00 + вечерний 19:00 (Morning Brew-модель). Тот же Content Object → DistributionAgent решает newsletter.slot.	Cost	~\$20/мес на 50K
Технически: Resend для email, Telegram Bot + WebPush для push.	Объём работ	+1 FTE-неделя
Себестоимость: \$20/мес на 50K писем.		

Style Dictionary — single source of design

Все три рендерера используют один и тот же набор design tokens, экспортируемых из Figma через Style Dictionary в три формата: tailwind.config.ts для веба, tokens.swift/kt для возможного native, и _pdf.css для квартального журнала. Это означает, что смена красного --red: #E63946 происходит **в одном месте** и автоматически прокатывается на все три канала. Это критичное решение, потому что без него уже через 6 месяцев Mini App, Web и PDF разойдутся в оттенках, межстрочниках и размерах.

КЛЮЧЕВОЕ РЕШЕНИЕ · ОДИН Next.js НА ДВА КАНАЛА

Mini App (TG/MAX) и Web Landing — **один Next.js проект**, два набора маршрутов. Это означает **90% общего кода** и единый CI/CD. Идентификация площадки через middleware: если запрос идёт с заголовком tgWebAppData — рендерим mini-app shell, если без — рендерим Web. Разница в layouts и пары компонентов, не в логике. Альтернатива — два отдельных проекта — была отвергнута в v1.0 как удорожание в 1.8× без выигрыша.

09 · ОТДЕЛЬНЫЙ ПРОДУКТ ПО УМОЛЧАНИЮ

«Пuls X10» — карта деловой активности сообщества

Уникальный data-актив, который не воспроизведёт ни РБК, ни Forbes, ни Т-Журнал: что обсуждают предприниматели в 30+ городах прямо сейчас. Реализация: отдельный модуль с собственной data-моделью, своей вкладкой в Mini App, своим B2B-API под feature flag.

Концептуальная модель

СУЩНОСТЬ

pulse_signal = (city, topic, sentiment, intensity, source_ref, ts). **City** — нормализованный город из 30 каталога клампов. **Topic** — извлечён SourceCuratorAgent из 200+ тегов. **Intensity** — взвешенная активность (упоминания, реакции, ответы).

РАСЧЁТ «ТЕПЛА» ПО ГОРОДАМ

Для каждой пары (city, topic) считаем **rolling 24h heat-score** = $\alpha \times \text{mentions} + \beta \times \text{engagement} + \gamma \times \text{velocity}$. $\alpha=0.5, \beta=0.3, \gamma=0.2$ (стартовая калибровка). Хранится в pulse_aggregates с обновлением раз в 30 минут.

Что видит читатель

MINI APP · ВКЛАДКА «ПУЛЬС»

Карта 30 городов, размер пульса = heat-score. Тап на город → 5 главных тем дня. Тап на тему → ссылка на источник (если публичный) + перефраз.

WEB · /PULSE

Та же карта, но с поиском по городу и подпиской на RSS. SEO-страница для каждой пары (city, topic).

B2B API · FEATURE FLAG

Доступ GET /api/pulse/cities/:city по токену. Целевые покупатели: банки, ритейл, региональные администрации. Цена: от 30K ₽/мес.

Каталог 30 каналов на старте

Список собирает Editor-in-Chief в МО через региональных лидеров. Стартовая выборка по городам с самыми активными клампами:

Москва	СПб	Краснодар	Екатеринбург
Уфа	Казань	Самара	Новосибирск
Иркутск	Сочи	Челябинск	Калининград
Ростов	Воронеж	Тюмень	Пермь
Омск	Барнаул	Хабаровск	Владивосток
Минск	Алматы	Ташкент	Дубай
Стамбул	Белград	Лимасол	Бали
+ 2 ротация	резерв		

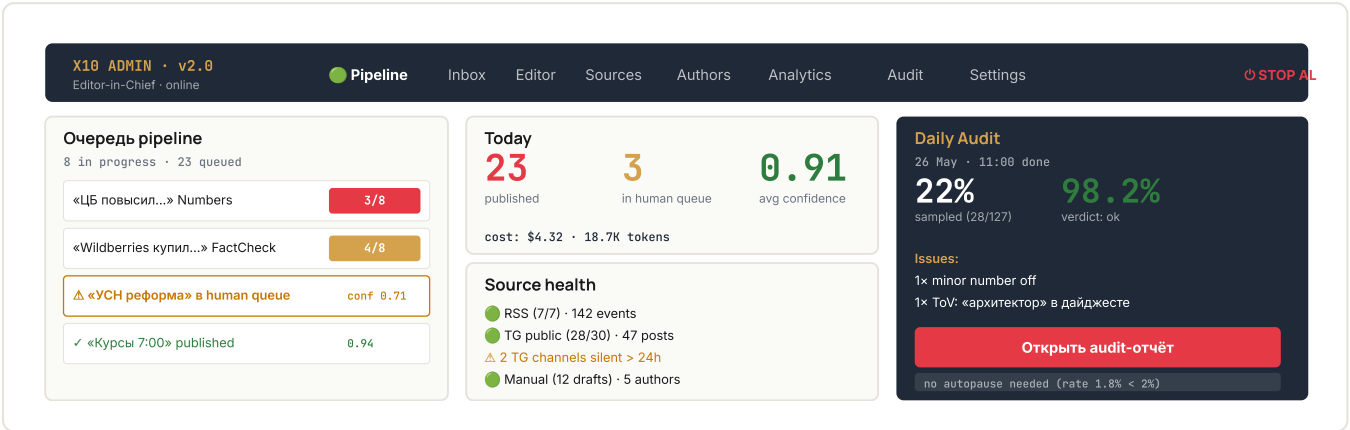
Что мы НЕ делаем в «Пulsе» (anti-goals)

НЕ делаем	Почему
Не показываем имена авторов постов	Защита от harassment + 152-ФЗ комфорт
Не цитируем дословно > 15 слов	Авторское право + наследие ToV-канона
Не агрегируем приватные/полузакрытые группы	Решение по развилке 1 · только public
Не строим персональный профиль клампера	Аналитика только агрегатная, без user-tracking
Не продаём raw-данные третьим лицам в МО-M12	Сначала product-fit, потом монетизация

Admin Console — диспетчерская AI-завода

Главный экран — не редактор статей, а **orchestration dashboard**. Редактор должен видеть, что фабрика делает прямо сейчас, какие материалы в очереди на человеческое решение, где упало доверие агентов, какие источники замолчали. Tiptap-редактор — только одно из семи окон.

Семь экранов



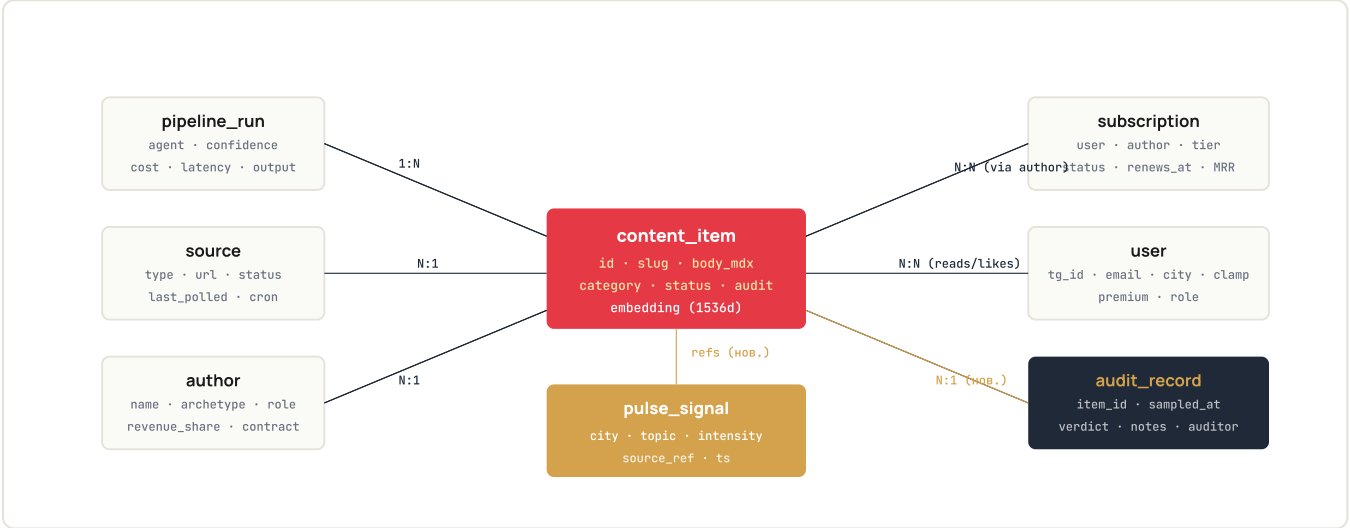
Семь экранов — описание

Экран	Назначение	Ключевые элементы	Доступ
1. Pipeline	Live-дашборд оркестратора	Очередь · health источников · today stats · audit	All
2. Inbox	Очередь human queue	Карточки с reason, confidence, source URL	Editor+
3. Editor	Tiptap + Yjs collaborative	Версионирование · комментарии · revision history	Author+
4. Sources	Управление источниками	RSS + TG channels · добавить/выключить	Editor+
5. Authors	Карта 8 авторов	OKR · MRR · revenue share · трудовой+самозанятый	EiC+
6. Analytics	PostHog-эмбед	DAU/MAU · retention · conversion воронка	All read
7. Settings	Confidence, kill switches	Пороги по категориям · аудит-лог · биллинг	Owner only (billing)

Data Layer — Neon + pgvector + Zero

Три типа данных, три механизма хранения. Транзакционные сущности — Neon Postgres. Embeddings — pgvector в том же кластере. Real-time presence/чаты для клампов — Zero (Rocicorp) sync engine. Это наследие Tech Roadmap v1.0, расширенное под нужды AuditAgent и «Пульса».

ER-схема (high-level)



Технологический выбор

NEON POSTGRES · FRANKFURT

Branch per environment (dev/staging/prod), point-in-time restore. Hyperdrive cache в Cloudflare Workers для < 100 ms p95 чтения с edge.

PGVECTOR

Размерность **1536** (стандарт для большинства embedding-моделей 2026). IVFFlat индекс для cosine-поиска. Дедуп + RAG для «Спроси X10».

ZERO (ROCICORP) SYNC ENGINE

Real-time presence + клампские чаты внутри Mini App. Offline-first. Read-after-write < 50 мс на 30K пользователей.

BACKUP И DISASTER RECOVERY

RPO (приемлемая потеря данных) — 5 минут. RTO (время восстановления) — 30 минут. Neon делает continuous backup в S3-совместимое хранилище, point-in-time restore доступен на любую точку за последние 7 дней. Дополнительно — daily snapshot в Yandex Object Storage для соответствия требованию локализации данных по 152-ФЗ копией внутри РФ. **Тест восстановления** раз в месяц обязательно, иначе backup не считается рабочим.

Что фабрика рассказывает о себе

Автопилот без наблюдаемости — слепой полёт. Три слоя инструментов: метрики (PostHog), ошибки (Sentry), трейсинг (OpenTelemetry). Поверх них — AuditAgent, который раз в день делает контентный аудит на 20% выборке. Если > 2% материалов содержат ошибки — автопауза категории до решения редактора.

Три инструмента наблюдаемости

МЕТРИКИ ПРОДУКТА

PostHog (self-hosted)

DAU/MAU, retention, conversion funnels Mini App + Web. Feature flags (используем для «Пульса»). Session replay для подозрительных багов. Cohorts по клапмам и городам.

Cost ~\$40/мес

ОШИБКИ ПРИЛОЖЕНИЯ

Sentry

Frontend (Mini App + Web + Admin), backend (Workers + Inngest workflows). Алерты в TG канал команды и Better Stack on-call. Performance monitoring — p95 латентность по экранам.

Cost ~\$26/мес (Team)


ТРЕЙСЫ ПАЙПЛАЙНА

OpenTelemetry + Honeycomb

Сквозной trace каждого прогона: ingestion → 8 агентов → publish. Latency по агенту, cost по агенту, confidence по агенту. Дашборд «Где упало?» — главный экран для AI Lead.

Cost ~\$35/мес

Daily Audit Loop · процедура



Rollback playbook

Тип проблемы	Действие	Время
Опубликована статья с ошибкой	Admin → Editor → unpublish → опц. публикация исправления с пометкой «Уточнение»	< 60 секунд
AuditAgent нашёл систематическую ошибку в категории	Автопауза категории → все материалы за день в human queue → AI Lead запускает ad-hoc audit на 100% и принимает решение	< 5 минут authom.
Агент сломался (latency × 3, либо confidence < 0.3 на 3 прогонах подряд)	Inngest auto-retry с backoff (3 раза). Если не сработало — агент disabled, pipeline идёт без него, в админке flag.	2 минуты authom.
Источник скомпрометирован (фейк-новость от RSS)	Source → disable → весь контент с этого источника помечается для re-audit	< 3 минуты
Полный отказ Anthropic API	Pipeline останавливается, все агенты в paused. SourceCurator продолжает копить очередь. Inngest auto-resume.	auto

КЛЮЧЕВОЕ ОБЯЗАТЕЛЬСТВО · АРХИВ ПРОГОНОВ ХРАНИТСЯ 90 ДНЕЙ

Каждый прогон каждого агента — вход, промпт, выход, confidence, latency, cost — пишется в pipeline_run с retention 90 дней. Это критично по двум причинам: **(1)** AuditAgent может ретроспективно перепроверить любую публикацию **(2)** при споре с источником («вы исказили моё интервью») у редакции есть полная цепочка трансформаций для разбора. Объём: ~ 30 МБ/день · 90 дней × 30 МБ = 2.7 ГБ → ~ \$0.50/мес на S3.

Что меняется в бюджете и что может пойти не так

Полная автономность сдвигает экономику AI с \$50 до \$250–400 в месяц и добавляет ~\$200/мес на инфраструктуру оркестрации и аудита. Это всё ещё пренебрежимо мало против OpEx ~30М Р/год, но другой профиль рисков, который нужно пройти осознанно.

AI-cost · детализация по агентам

Агент	Модель	Прогонов/день	Cost/прогон	Cost/мес (30 дн)
SourceCurator NEW	Haiku 4.5	200	\$0.001	\$6
Draft	Sonnet 4.6	30	\$0.012	\$11
Numbers	Sonnet 4.6	30	\$0.009	\$8
FactCheck	Opus 4.7	30	\$0.085	\$77
ToV-Agent	Sonnet 4.6 + RAG	30	\$0.015	\$14
Brevity	Sonnet 4.6	30	\$0.008	\$7
Audio (опц.)	ElevenLabs	15	\$0.040	\$18
Distribution NEW	Haiku 4.5	30	\$0.001	\$1
AuditAgent NEW	Opus 4.7	6 (20%)	\$0.120	\$22
ИТОГО AI pipeline · базовый сценарий				~ \$164/мес
+ «Пульс» (aggregation + B2B-API runtime)				~ \$80/мес
+ резерв на retries и FactCheck в категории high-risk (×2)				~ \$80–150/мес
ВСЕГО · v2.0 эксплуатация				\$324–414/мес

Сравнение с v1.0: **\$50/мес** в базовом сценарии (без автопилота). Прирост ~\$300/мес = **~30К Р/мес**. На фоне совокупного OpEx 30М Р/год (~2.5М Р/мес) — это **1.2% издержек**. Замещает 0.3 FTE редактора → окупается с многократным запасом.

Инфраструктура · delta v2.0

Inngest (workflow engine)	\$25 → \$75/мес
Honeycomb (OTel backend)	+ \$35/мес
Дополнит. Neon compute	+ \$30/мес
Хранение pipeline_runs (S3)	+ \$1/мес
Better Stack on-call	+ \$25/мес

ОБЩИЙ БЮДЖЕТ V2.0

AI pipeline + инфраструктурный delta + Audit + резервы

\$490–580/мес

~ 45–55 К Р/мес при курсе 92 Р/\$

Матрица 10 ключевых рисков

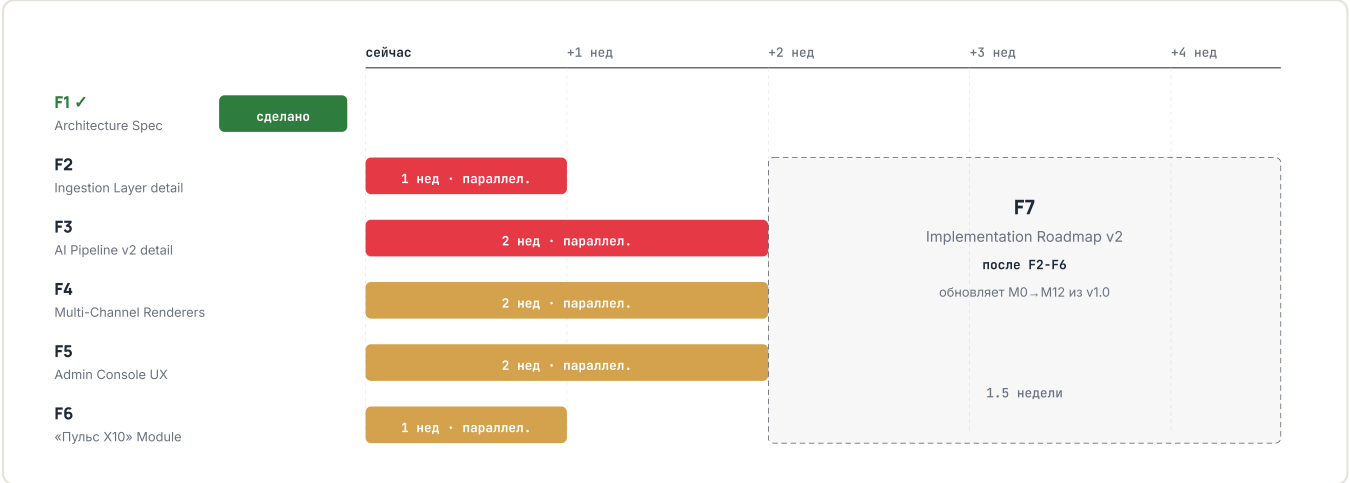
#	Риск	P	I	Митигация
1	Окно повреждения 30 публикаций между аудитами	M	H	BLOCKING-категории всегда human · per-category kill switches · post-hoc < 24h
2	RSS-источник закрывается (РБК заблокировал feed)	M	M	fallback feedburner + 7 источников диверсификация
3	TG Bot API rate-limit или закрытие 30+ каналов	L	M	2 бота-парсера в ротации · ручной добор источников
4	Авторские права: иск от СМИ за агрегацию	L	H	цитаты < 15 слов · ToV-канон ссылок · юрист на ретейнере с М3
5	Дрейф confidence-калибровки	M	M	еженедельный shadow-тест на 50 фиксированных образцах

14 · ПЛАН СЛЕДУЮЩИХ ШЕСТИ ФАЗ

Что мы делаем после F1

Серия v2.0 расписана на семь фаз. Этот документ — F1, фундамент. Фазы F2–F6 могут идти **параллельно**, потому что зависят от F1, но не друг от друга. F7 — финальный, потому что переписывает Implementation Roadmap из v1.0 с учётом v2.0-решений и должен интегрировать все детали из предыдущих фаз.

Gantt-диаграмма фаз



Содержание каждой фазы

Фаза	Название	Что покрывает	Deliverable
F2	Source Ingestion Layer	RSS-парсеры детальный код · TG Bot API настройка · cron-расписание · дедупликация SimHash + pgvector · KikuAI Masker integration · алертинг про silent sources	PDF 14–18 стр.
F3	AI Pipeline v2 detail	Промпты всех 8 агентов · схема Inngest workflows · retry logic · confidence-метрики · shadow-режим калибровки · AuditAgent prompt + sampling алгоритм	PDF 18–22 стр. + промпты MDX
F4	Multi-Channel Renderers	Next.js routing для Mini App + Web · PPR конфигурация · Style Dictionary tokens · Playwright PDF template · PWA опционально	PDF 14–16 стр. + код-каркасы
F5	Admin Console UX spec	Wireframes 7 экранов · Figma-файл · права RBAC детально · Tiptap+Yjs schema · audit-журнал UI	PDF 16–20 стр. + Figma
F6	«Пульс X10» Module	Каталог 30 каналов финальный · heat-score формула + калибровка · B2B-API контракты · feature flag механика · юр.формат продукта	PDF 10–14 стр.
F7	Implementation Roadmap v2	Обновлённый M0 → M12 с FTE-картой v2.0 · бюджеты · milestones · go/no-go criteria · переход от v1.0-плана	PDF 12–16 стр. + Excel-обновление

ПОЧЕМУ ПАРАЛЛЕЛЬНО, А НЕ ПОСЛЕДОВАТЕЛЬНО

F1 зафиксировал контракты между контейнерами. Это значит, что человек, делающий **F3 Pipeline detail**, не должен знать, как именно нарисован экран в **F5 Admin Console** — ему достаточно знать, что админка читает `pipeline_run` и пишет в `switches`. Декомпозиция через интерфейсы — это то, ради чего пишется architecture spec. Если бы фазы зависели друг от друга — это означало бы, что F1 не справился со своей работой.

15 · РЕШЕНИЯ ДО СТАРТА F2

Что нужно решить, и что мы НЕ покрыли

F1 — это контракты и принципы, но не реализация. Перед стартом F2 нужно закрыть пять открытых вопросов, у каждого из которых архитектурные последствия. Также фиксируем, что осознанно осталось за рамками F1 — чтобы не было удивлений в F2–F7.

Пять решений до старта F2

01

WORKFLOW ENGINE: INNGEST ИЛИ TRIGGER.DEV V3?

Рекомендация: Inngest (managed, \$0 до 50K runs, UI из коробки). Trade-off: vendor lock-in vs. экономия 2 FTE-недель. Решает: AI Lead / CTO. Когда: до начала F3.

02

ЮР.ФОРМА «ПУЛЬСА» КАК ПРОДУКТА

Если B2B-API «Пulsar» — отдельный продукт под подпиской, нужна **самостоятельная оферта** с условиями использования данных (license terms). Решает: **юрист на ретейнере** до старта F6.

03

ЛИЦЕНЗИРОВАНИЕ RSS-АГРЕГАЦИИ ОТ СМИ

7 RSS-источников (РБК, Forbes...) технически открыты, но **агрегация в коммерческом продукте** может потребовать партнёрской лицензии (как Apple News). Решает: коммерческий директор X10 до начала M2.

04

EMBEDDING-МОДЕЛЬ: VOYAGE AI / OPENAI / COHERE?

Voyage AI сейчас лидирует на benchmarks для русского текста, но самый дорогой. **OpenAI text-embedding-3-small** — стандарт по цене. **Cohere** — компромисс. Решает: AI Lead, нужен benchmark на 50 ru-текстах.

05

ЛОКАЛИЗАЦИЯ ДАННЫХ В РФ · YANDEX OBJECT STORAGE КАК BACKUP-ЗЕРКАЛО

Neon в Frankfurt + daily snapshot в Yandex Cloud Object Storage = соответствие **152-ФЗ**: «копия персональных данных в РФ». Но это требует **отдельного договора с Yandex Cloud** и оформления как обработчика ПДн. Решает: **юрист + DPO до M2**.

Что НЕ покрыто в F1 (осознанные выпуски)

Тема	Куда вынесено
Production-код любого контейнера	F2–F6 (per-container deep dives) и фаза имплементации в Roadmap v2 (F7)
Figma-макеты Admin Console и Mini App	F5 Admin UX spec — wireframes; для Mini App — расширение существующего прототипа сессии 1
Финальные тексты промптов для 8 агентов	F3 AI Pipeline detail — отдельный MDX-репозиторий промптов с версионированием
Юридические контракты с авторами и B2B	Юрист на ретейнере с M2 — отдельный workstream вне серии v2.0
Маркетинг-план запуска и go-to-market	Strategy v1.0 уже покрывает GTM; обновление в F7 Roadmap v2
Финмодель v2.0 с учётом новых cost	F7 + обновление Excel-файла «X10_Daily_финмодель_12мес.xlsx»

Связь с серией v1.0

Серия v1.0 (7 документов) — это **контекст и стратегия**. Серия v2.0 — это **исполняемая архитектура** с акцентом на автономность. Документы v1.0 остаются в силе как источник правды по **бренду** (Strategy, ToV, Rewrites), **конкурентам** (Competitive), **миграции редакции** (Editorial Migration), **бизнес-модели** (финмодель) и **базовому тех-стеку** (Tech Roadmap). Серия v2.0 расширяет Tech Roadmap v1.0 в части AI-конвейера и поверх ставит автономную оркестрацию.

СЛЕДУЮЩАЯ СЕССИЯ · СТАРТОВЫЙ ПРОМПТ

«Открываю F2 · **Source Ingestion Layer detail**. Опираюсь на F1: три типа источников (RSS, TG public Bot API, manual), 5-этапный pipeline (Fetch → Normalize → Dedupe → PII Mask → Enqueue), Cloudflare Workers + cron. Цель F2: код-каркас всех парсеров, схемы TG Bot API webhook, конфигурация KikuAI Masker, dedup-индекс на pgvector с порогом 0.85, runbook для silent-source детекции. Deliverable: PDF 14–18 стр. в той же дизайн-системе.»

X10-ARCHITECTURE-SPEC-v2.0.pdf · next

16 / 16