

Технический роадмап M0 → M12

Стек 2026 года для мини-аппа в Telegram и MAX, AI-пайплайн контента из шести агентов, ramp-up команды от 1 до 6 FTE, и ежемесячный бюджет на 12 месяцев — внутри общего OpEx в 30 млн ₽.

ВЕРСИЯ
v1.0

ДАТА
25 мая 2026

СВЯЗАННЫЕ ДОКУМЕНТЫ
Strategy v1.0 · ToV v1.0 · Финмодель · Rewrites

EXECUTIVE

Что строим и сколько это стоит — на одной странице

X10 Daily — мини-апп в Telegram и MAX с веб-зеркалом и AI-пайплайном контента. Год разработки укладывается в **18,9 млн ₽**, что внутри Base-OpEx 30,5 млн ₽ из финмодели. Главная архитектурная ставка — instant-data ощущение Linear/Notion при mobile-first ограничениях Telegram Mini App.

18,9M

₽ НА РАЗРАБОТКУ ГОД · ФОТ + ИНФРА + AI

6

FTE ИНЖЕНЕРНЫХ К M12 · RAMP ОТ 1 В МО

6

AI-АГЕНТОВ В ПАЙПЛАЙНЕ КОНТЕНТА ДО ПУБЛИКАЦИИ

400мс

DOHERTY THRESHOLD · GOVERNING BUDGET UX

Семь решений по стеку, на которых держится бюджет

РЕШЕНИЕ	ЧТО ВЫБИРАЕМ	ПОЧЕМУ ИМЕННО ТАК — В ОДНОЙ СТРОКЕ
Rendering	Next.js 16 + PPR (Partial Prerender)	Static shell на edge + streamed dynamic holes — это TTFB ≤ 200 мс без cold start.
Compute	Cloudflare Workers + Hono v4	V8 isolates без cold start; Hono — единый TS-роутер frontend↔backend.
Database	Neon Postgres + Hyperdrive cache	Branching для preview, edge-кэш чтения < 5 мс на hit, RU-регион Frankfurt.
Sync engine	Zero (Rocicorp) для клампских чатов	Local-first IndexedDB + LWW per-property, мутация ≤ 16 мс локально.
LLM	Claude Sonnet 4.6 (агенты) + Haiku 4.5 (роутинг)	\$3/\$15 за MТок на ядре, \$1/\$5 на префилт্রে; ZDR-контракт с первого дня.
TTS / Audio	ElevenLabs через свой WebSocket-прокси	Голос автора, обход блокировки ElevenLabs в РФ через Render-прокси.
Editor	Tiptap + Yjs (collaborative)	ProseMirror-стандарт, мульти-курсор для редактуры, plug-ins для AI-агентов.

КЛЮЧЕВОЙ ВЫБОР

Двойной стек хостинга с первого дня

Cloudflare Workers — основной runtime для зарубежной аудитории и edge. **Yandex Cloud Functions** — фолбэк через GeoDNS для РФ. Так мы не зависим ни от блокировок Cloudflare, ни от санкционных рисков на Workers. Стоимость удвоения — ~30К ₽/мес, цена защиты — критическая.

ПРИНЦИПЫ

Четыре правила «мирового уровня» 2026

Это не «best practices» — это инженерные ограничения, которые превращают абстрактное «сделать классно» в обоснованный выбор. Если их нарушить — переписывать придётся всё.

01 · INSTANT DATA

«Мгновенно» — это не быстрая БД

Канон Linear / Figma / Notion / Superhuman: **локальный кэш + очередь транзакций + дельта-стрим**. Мутация никогда не вызывает сеть — она кладёт транзакцию в персистентную очередь. UI рендерит «кэш + очередь». Сеть приходит дельтами по WebSocket/SSE.

Для X10 Daily: применяем к клампским чатам, комментариям, реакциям, сохранениям (Zero sync engine). Для ленты — Server Components с PPR и kv-кэшем edge.

Бюджет локальной мутации: **≤ 16 мс** (один кадр на 60 fps).

02 · MOBILE-FIRST КАК T3

Мини-апп — это контракт, а не «адаптив»

Telegram WebApp SDK 7.x запускается в WebView внутри клиента, с жёсткими лимитами: bundle JS < **200 KB** gzipped на entry, открытие < **1,5 с**, edge-swipe конфликтует с системным back. MAX Mini App + Platform Bridge — отдельный набор ограничений.

Для X10 Daily: мы НЕ грузим лонгриды целиком — стримим контент по Suspense-границам. Видео-плеер lazy-load. Push спрашиваем после первого ценного действия, не сразу.

Если ассет > 100 KB — он lazy. Если бандл > 200 KB — режим фичу.

03 · AI-NATIVE, НЕ AI-FEATURE

AI — это инфраструктура, не «волшебная кнопка»

Каждая статья проходит конвейер из **6 агентов** (стр. 9), каждый комментарий клампа сжимается AI-резюме, каждое аудио — синтез ElevenLabs голосом автора. AI не «помогает редактору» — он **часть процесса публикации**, с human-in-loop на каждом узле.

Streaming-first: Vercel AI SDK 6, SSE-потoki, скелетоны TTFT ≤ 500 мс. Никаких блокирующих ожиданий «LLM думает».

Бюджет TTFT: **≤ 500 мс** (responsive), **≤ 200 мс** — отлично.

04 · EDGE-FIRST + 152-ФЗ

Глобальный edge, российский compliance

Cloudflare Workers — глобально, без cold start, V8 isolates. Но для РФ — **двойной стек**: Yandex Cloud Functions через GeoDNS-фолбэк, чтобы блокировка Cloudflare не убила сервис. Все ПДн обезличиваются через **KikuAI Masker** перед отправкой в LLM (152-ФЗ).

Для X10 Daily: Neon в Frankfurt, R2 для blob, PII-маскирование как middleware — не «потом подключим», а с первого коммита.

Edge read p95 **≤ 50 мс**, PII в LLM **0%**.

МЕТРОЛОГИЧЕСКИЕ БЮДЖЕТЫ

Это не рекомендации — это границы приёмки фич

LCP ≤ 2,5 с · INP ≤ 200 мс · TTFB ≤ 200 мс · CLS ≤ 0,1 · TTFT ≤ 500 мс · Doherty 400 мс · Mini App open ≤ 1,5 с · Bundle ≤ 200 KB gzipped. Если фича не укладывается — она не релизится, фича переписывается. Эти числа идут в Definition of Done каждой задачи в Linear с первого спринта.

АРХИТЕКТУРА

Карта системы за одну страницу

Три слоя: клиенты (Telegram/MAX/web), edge (Workers + Hyperdrive), origin (Neon + AI).
Поток мутаций — оптимистичный с server-authoritative LWW. Поток контента — асинхронный конвейер с human-in-loop.

КЛИЕНТЫ

TELEGRAM
Mini App SDK 7.x
WebView, BackButton API, ClosingConfirmation, HapticFeedback. Основной канал.

MAX
Mini App + Bridge
VK Platform Bridge для кросс-канального ID. Запуск в M5.

WEB
Next.js 16 SSR
SEO-зеркало для лонгридов + редакционный CMS. M6+.

EMAIL
Resend + React Email
Morning Brew формат. Конверсия → Mini App.

EDGE (CLOUDFLARE + YANDEX CLOUD)

HONO API
tRPC v11 router
Workers V8 isolates, без cold start. Все мутации идут сюда. Auth — Telegram initData (HMAC-SHA256).

HYPERDRIVE
Edge read cache
PG-кэш p95 < 5 мс на hit. Авто-инвалидация по триггерам Neon.

DURABLE OBJECTS
Per-clamp state
SQLite-backed, real-time чаты клампов. WebSocket coordination.

YANDEX CLOUD FUNCTIONS — ФОЛБЭК
GeoDNS-route для РФ при блокировке Cloudflare
Тот же Hono-роутер, deployed parallel. Стоимость удвоения — ~30K ₽/мес.

DATA + AI ORIGIN

NEON POSTGRES
Frankfurt · branching
Source of truth. pgvector для RAG-индекса контента.

R2
Blob storage
Видео, аудио, изображения. CDN бесплатный egress.

ZERO
Sync engine
Local-first IndexedDB ↔ Postgres. Realtime via WebSocket дельтами.

ANTHROPIC API
Sonnet 4.6 + Haiku 4.5
6 агентов контент-пайплайна. ZDR-контракт с Anthropic.

ELEVENLABS
Через свой проху
Render.com WebSocket-bridge для обхода блокировки в РФ.

MASKER
KikuAI · PII
Обезличивание ПДн перед LLM. 152-ФЗ compliance.

МУТАЦИЯ
Client → Zero queue (16 мс UI-ответ) → Hono на Workers → Neon → WebSocket-дельта другим клиентам.

ЧТЕНИЕ
Client → Workers → Hyperdrive cache hit (5 мс) или Neon read replica (50 мс p95).

КОНТЕНТ-ПАЙПЛАЙН
Tiptap → 6 агентов Claude через Workers Queue → редактор approves → publish + index в pgvector.

СТЕК · 1/3

Frontend и Edge — как открыть мини-апп за 1,5 секунды

Главная проблема Telegram Mini App — WebView без HTTP/3 и со старыми JS-движками на дешёвых Android. Дефолт «React + clientside fetching» здесь не работает. Стратегия: **static shell на edge + streaming dynamic holes + локальный кэш для повторных открытий**.

СЛОЙ	ТЕХНОЛОГИЯ	ПОЧЕМУ ИМЕННО ЭТА
Rendering	Next.js 16 App Router PPR (Cache Components, 'use cache', cacheLife, cacheTag)	Статический shell prerendered на edge + Suspense-границы для dynamic данных в одном HTTP-ответе. TTFB ≤ 200 мс без полной серверной генерации каждой страницы.
Mobile shell	React 19 + Tailwind 4 shadcn/ui (lift'n'shift)	Server Components на чтение, useOptimistic + useFormStatus + useActionState на мутации. Мини-апп — это, по сути, мобильный SPA-shell с RSC-границами.
Tg Bridge	@telegram-apps/sdk 2.x + Platform Bridge для MAX	Каноничный TS-SDK Telegram (форк from twa-dev). Platform Bridge — единый API для запуска одного и того же app в Tg и MAX. Подробно в skill max-bot-miniapp.
Compute	Cloudflare Workers + Hono v4 router	V8 isolates без cold start. Hono — единый TS-роутер frontend↔backend, ~14 KB размер runtime. Размещение в 300+ CDN-точках, для РФ — Helsinki / Stockholm POPs.
API style	tRPC v11 + Zod (никакого REST)	End-to-end TypeScript: типы router'а импортируются в клиент. Type-safety без OpenAPI-генерации. Дедупликация запросов и оптимистичные мутации — встроены.
Client cache	TanStack Query v5	Нормализованный клиентский кэш + bg-refetch + suspense-mode. Поверх — Zero sync engine для real-time дельт (см. стр. 6).
Fallback хостинг	Yandex Cloud Functions (тот же Hono router)	GeoDNS-route на ru-зону при детекте РФ-трафика. Если Cloudflare заблокирован — переключение прозрачное за < 60 с. Cold start ~1,2 с — единственный компромисс.

ЭТО ВАЖНО ПОНИМАТЬ

Бюджет 200 KB JS на entry — это не «постараемся», а архитектурное правило

В Telegram WebView на дешёвом Android (Xiaomi Redmi 9, 2 GB RAM) парсинг 1 MB JS — это **~800 мс на main thread**. Это значит белый экран и потерянная сессия. Поэтому: **1)** Server Components на 90% UI, клиентский JS — только для интерактива; **2)** Каждая фича проходит size-budget review перед мержем; **3)** Heavy либы (видео-плеер, charts) — dynamic import после первого пользовательского действия.

СТЕК ·
2/3

Данные — Postgres origin + Zero local-first + edge cache

Postgres остаётся source of truth, но клиент видит данные через **три слоя кэширования**: локальный IndexedDB (мгновенно), Hyperdrive на edge (5 мс), Neon read replica (50 мс p95). Real-time апдейты идут отдельным WebSocket-каналом дельтами, не пересборкой страницы.

СЛОЙ	ТЕХНОЛОГИЯ	ЧТО ХРАНИТ / ЗАЧЕМ
Origin DB	Neon Postgres 17 Frankfurt · branching	Все доменные сущности: статьи, авторы, читатели, реакции, кламповая структура, события, подписки, биллинг. Branching для preview-deploys.
Edge cache	Cloudflare Hyperdrive + KV для prefs	PG connection pool + read cache на 300+ edge-узлах. P95 hit ≤ 5 мс. KV — для пользовательских настроек, A/B-флагов, фичеров.
Per-tenant	Durable Objects + SQLite	Состояние одного клампа (8-10 человек) живёт в одном DO с собственной SQLite. Real-time координация через WebSocket внутри DO — без round-trip в Neon.
Sync engine	Zero (Rocicorp)	Local-first IndexedDB на клиенте + сервер-authoritative LWW per-property. Мутация = транзакция в очередь (16 мс UI) → дельта по WS другим клиентам.
Collab editor	Tiptap + Yjs (ProseMirror-стандарт)	Совместное редактирование статьи редакторами (CRDT per-character). Hocuspocus для синхронизации, y-indexeddb для оффлайна.
Vector store	pgvector в Neon + Voyage-3 эмбединги	Семантический индекс всего контента (≤ 1M документов на 12 мес — справится без отдельного сервиса). Для RAG-агентов и персональной ленты.
ORM / migrations	Drizzle ORM	TS-first, zero-runtime, миграции через drizzle-kit. Абстрагирует Postgres от Хоно — при необходимости свапнем БД.
Object storage	Cloudflare R2 + CDN	Аудио лонгридов, видео-разборов, обложки. R2 = S3-API без egress-стоимости. Картинки трансформируются Cloudflare Images.

КЛАМПСКИЙ ЧАТ

Почему Zero, а не Convex / Replicache

Convex — отличный, но это новая БД (lock-in). Replicache — требует ручной сборки сервера. **Zero** — это *та же Postgres*, к которому добавлен sync-layer. Никакого новой БД, миграция на классический PG любая в час ноль. Open source. Production с 2025.

RAG ДЛЯ ПЕРСОНАЛИЗАЦИИ

«Спроси X10» — RAG поверх контента Рыбакова

В M9 запускаем чат-помощник на pgvector. **Запросы embedding'ом** Voyage-3 (мультиязычный) против индекса ~500К статей/постов/видео-расшифровок Рыбакова. **Ответ генерит Claude Sonnet 4.6** с citation в исходники. TTFT ≤ 500 мс через streaming.

СТЕК · 3/3

AI-слой — Claude, ElevenLabs, pgvector и 152-ФЗ

AI здесь — не одна модель, а **портфель из четырёх типов сервисов**: LLM-агенты, TTS, embeddings, PII-masking. Каждый — со своими SLA, ценой и compliance-требованиями. Главное правило: **0% ПДн в любую модель из США**.

НАЗНАЧЕНИЕ	СЕРВИС / МОДЕЛЬ	ЦЕНА	ЗАЧЕМ ИМЕННО ЭТА
Агенты контента	Claude Sonnet 4.6	\$3 / \$15 за MTok	Дефолт для всех 6 агентов пайплайна. Балансирует качество, скорость, цену. 1M context — для длинных интервью.
Префильтр / роутинг	Claude Haiku 4.5	\$1 / \$5 за MTok	Классификация, тегирование, выделение цитат, простой extract. 80% дешевле Sonnet на массовых задачах.
Сложные кейсы	Claude Opus 4.7	\$5 / \$25 за MTok	Только для FactCheck в политически чувствительных темах (риск ошибки = публичный скандал). ≤ 10% объёма.
TTS (озвучка)	ElevenLabs Multilingual v2 через WebSocket-прокси	\$0,18 / 1K символов	Голос автора (voice cloning из 1 часа речи). Streaming через свой прокси на Render.com — обход блокировки в РФ.
Embeddings	Voyage-3 (multilingual) в pgvector	\$0,12 за 1M токенов	Лучшее качество русского embedding на 2026. Cohere multilingual-v3 — fallback. Размер вектора 1024.
PII masking	KikuAI Masker (self-hosted на Render)	~\$25 / мес (инфра)	Все ПДн (имена клиентов, телефоны, ИНН, адреса) заменяются на плейсхолдеры ДО отправки в LLM. Session cache для мультитурна.
SDK на клиенте	Vercel AI SDK 6	бесплатно	Streaming markdown через SSE, useChat/streamObject, абстракция провайдеров. Запасной путь — OpenAI / Mistral через LiteLLM-proxy.
Observability	Helicone + Langfuse	\$50 / мес	Логи каждого вызова, latency-percentiles, token-spend по агентам. Без этого слой AI — чёрный ящик в проде.

ОПТИМИЗАЦИЯ СТОИМОСТИ
Два рычага, которые экономят 60-90%

1. **Prompt caching** — статичные части промптов (ToV-чёрный список, примеры стиля Smart Brevity, схема ответа) кэшируются на 10 мин. Cached input — **\$0,30 за MTok** вместо \$3,00 (90% off на этих сегментах).

2. **Batch API** — для агрегации ночных дайджестов, переиндексации, пакетного перевода — **50% off** на всех моделях. Job завершается за < 24 ч, чего достаточно.

152-ФЗ · КРИТИЧНО

Маскирование ДО LLM — не «потом подключим»
Anthropic — резидент США. По 152-ФЗ + 266/420/421-ФЗ передача ПДн россиян в США **без обезличивания** = риск Роскомнадзора. **KikuAI Masker** с session caching ставится middleware'ом между Hono и Anthropic SDK. Без маскира — LLM-агенты вообще не получают user-generated данные. Подробно в skill 152-fz-foreign-llm-compliance.

КЛИЕНТЫ

Telegram и MAX — два рантайма, одна кодовая база

Telegram — основной канал (бот Рыбакова, аудитория уже на платформе). MAX — стратегический фолбэк (государственный курс на отечественные платформы, бесплатные пуши, потенциал захвата rural-аудитории). Запускаем оба с общим UI-shell через Platform Bridge.

TELEGRAM M2 · ОСНОВНОЙ ЗАПУСК

Mini App SDK 7.x — что используем

- **initData** — HMAC-SHA256 валидация на Workers (не клиенте)
- **BackButton API** — нативная навигация, не свой history-stack
- **ClosingConfirmation** — только в платных потоках (Premium)
- **HapticFeedback** — на ключевых действиях (like, save, share)
- **MainButton** — primary CTA на каждом экране
- **BiometricManager** — для Premium-входа без пароля (опционально M9+)
- **requestWriteAccess** — после первого ценного действия, не сразу
- **Theme params** — наследуем тёмную / светлую тему клиента

Подводный камень: edge-swipe конфликтует с системным «back» в iOS. Нужны safe-margins по горизонтали для карусели дайджеста.

MAX M5 · СТРАТЕГИЧЕСКИЙ ФОЛБЭК

Mini App + Platform Bridge — что важно знать

- **platform-api.max.ru** — официальный bot API, REST
- **VK Platform Bridge** — единый SDK для VK + MAX
- **Бесплатные push** — нет лимитов как у Telegram
- **Web SDK ~аналогичный Tg** — initData, MainButton, BackButton
- **Канал** — авторазмещение через Bot API в канале X10
- **Аудитория** — пока меньше Tg, но РФ-рост 30% MoM
- **Регулирование** — RU-резидент, нет рисков блокировки
- **WebApp domain** — нужно зарегистрировать заранее

Подводный камень: валидация initData отличается от Tg по HMAC-схеме. Нужна отдельная middleware. Подробно в skill max-bot-miniapp.

Стратегия общего кода — что переиспользуем

СЛОЙ	TELEGRAM	MAX	ОБЩИЙ КОД · 90%
UI-shell (компоненты, экраны)	✓	✓	React 19 + Tailwind 4, RSC-границы одинаковы.
Бизнес-логика, API-клиент	✓	✓	tRPC v11 типы импортируются из Hono.
Аутентификация (initData)	✓	✓	Разная схема HMAC — две middleware с одним интерфейсом.
Платформенные API (back, haptic, main)	Tg SDK	Bridge	Один platformAdapter.ts — фасад с одинаковыми сигнатурами.
Пуши и нотификации	Bot API	Bot API	Один сервис рассылки, две интеграции backend-side.
Сборка / deploy	CF Pages	CF Pages	Один build, разные subdomains (tg / max). Edge-функции одинаковые.

КОНВЕЙЕР

AI-пайплайн контента — шесть агентов до публикации

Журналист сдаёт сырой драфт в Tiptar → за **90 секунд** агенты возвращают 6 параллельных версий с diff-метками → редактор аппрувит/правит side-by-side → публикация. **Ничего не уходит в прод без человека.** Это и есть отстройка от инфоцыган-генеренки.

ВХОД

Tiptar-драфт

Сырой текст журналиста + audio-расшифровка + источники.

01 · DRAFTAGENT

Структура Smart Brevity

Разбивает сырой текст на 6 блоков: Tease / Lede / Why it matters / By the numbers / Yes but / What's next.

02 · NUMBERSAGENT

Цифры с источниками

Находит «много / мало / часто» — превращает в цифры с link на первичный источник. Помечает невалидируемое ●.

03 · FACTCHECKAGENT

Утверждения → источники

Выделяет каждое утверждаемое заявление, ищет первоисточник через web_search. **Opus 4.7** на политически чувствительных темах.

04 · TOV-AGENT

Чёрный список → замены

Прогон по ToV v1.0: ~30 запрещённых слов («соборное мышление», «архитектор возможностей»), регалии > 2, выдуманные цитаты.

05 · BREVITYAGENT

Режет до 280-300 слов

Целевой объём = 25-30 секунд чтения. Без потери цифр и атрибуций. Сильные глаголы, активный залог.

06 · AUDIOAGENT

ElevenLabs синтез

Озвучивает финальную версию голосом автора. Pause-маркеры, intonation hints от Claude. Кладёт MP3 в R2.

HUMAN GATE · РЕДАКТОР

Side-by-side diff approval

Редактор видит 6 версий через Tiptar-расширение с track-changes. Approves блочно или правит вручную. **Без approve — не публикуется ничего.**

ВЫХОД

PUBLISH

+ index в pgvector
+ пуш в каналы.

КЛЮЧЕВЫЕ ИНЖЕНЕРНЫЕ РЕШЕНИЯ

- **Workers Queues** между агентами — асинхронная очередь, ни одна задача не теряется.
- **Parallel exec**: 01-02-03 запускаются одновременно (не зависимы), 04-05 — после 01, 06 — после 05.
- **Prompt cache**: чёрный список ToV (3K токенов) — кэшируется на 10 мин, экономия 90% input на ToV-Agent.
- **SSE streaming** наружу: редактор видит, как генерится каждая версия в реальном времени, не ждёт всех 90 с.
- **Fallback model**: если Claude API down — LiteLLM-прокси переключает на Mistral Large 2 / GPT-5 за 5 с.

ПРАВИЛО НОЛЬ

Ни одна публикация — без человека

После кейса Шабутдинова (7 лет колонии, 31.10.2025) автогенерация даже намёка на «успешный успех» = репутационный crash.

Поэтому архитектурно: publish API требует editor_id и approved_at с подписью. AI-агенты могут только *предложить*, опубликовать — только редактор. Это не процесс — это код.



Сколько стоит AI-обработка одной статьи и одного DAU

Считаем честно по актуальному pricing Anthropic (май 2026) и реальному объёму контента — 5 статей в день × 22 рабочих дня = **110 статей/мес** в Base-сценарии. Плюс — персонализация ленты, голосовое саммари, «Спросы X10» с M9+.

Себестоимость одной публикации по агентам

АГЕНТ	МОДЕЛЬ	INPUT · ~ТОК.	OUTPUT · ~ТОК.	ЦЕНА	ЗАМЕТКИ
01 · DraftAgent	Sonnet 4.6	5 000	2 000	\$0,045	Системка кэшируется (90% off на input).
02 · NumbersAgent	Sonnet 4.6	3 000	800	\$0,021	+ 1-2 web_search (\$0,01).
03 · FactCheckAgent	Sonnet 4.6	4 000	1 200	\$0,030	10% случаев — Opus 4.7 (×3 цена).
04 · ToV-Agent	Haiku 4.5	4 000 cached	1 500	\$0,009	ToV-список (3К) — в кэше → \$0,30/MTok.
05 · BrevityAgent	Sonnet 4.6	2 500	800	\$0,020	Финальный режущий проход.
06 · AudioAgent (TTS)	ElevenLabs v2	1 800 символов		\$0,32	Голос автора, 8-минутный аудио-формат.
Итого / статья	микс	~18 500	~6 300	\$0,45	= ~42 ₽ за полную обработку (75 ₽/\$).

Месячный AI-бюджет в трёх сценариях

BEAR · 60 СТАТЕЙ/МЕС

\$27

~2 000 ₽ / МЕС — ПАЙПЛАЙН КОНТЕНТА

+ персонализация ленты (M6+) ~\$30 = **\$57/мес**. Воркфлоу для редколлегии — минимум, остаток ручной.

BASE · 110 СТАТЕЙ/МЕС

\$50

~3 750 ₽ / МЕС — ПАЙПЛАЙН КОНТЕНТА

+ персонализация (M6+) ~\$80 + «Спросы X10» RAG (M9+) ~\$200 = **\$330/мес → ~25К ₽/мес** на пике.

BULL · 200 СТАТЕЙ/МЕС

\$90

~6 750 ₽ / МЕС — ПАЙПЛАЙН КОНТЕНТА

+ персонализация ~\$200 + RAG ~\$400 + B2B-выпуски (CFO Brew style) ~\$150 = **\$840/мес → ~63К ₽/мес**.

ВЫВОД

AI — самая дешёвая статья расходов в проекте

В Base-сценарии AI = **~300К ₽/год** при общем OpEx 30М ₽ = **1% бюджета**. Это меньше, чем стоит один редактор за месяц. **Главный риск — не цена**, а: 1) ZDR-контракт с Anthropic (нужен от первого вызова), 2) PII-маскирование (152-ФЗ), 3) latency через РФ. На скейле — **prompt caching** и **batch API** снимают ещё 60-90% сверху.

M0 →
M6

Roadmap фаза 1 — от пустого репозитория до публичного запуска

Шесть месяцев на путь «закрытая бета на кламперах → GA с MAX-каналом и e-mail рассылкой». Каждая фаза заканчивается метрикой выхода — без её достижения следующая не открывается. Это не дедлайны, это gates.

M0 · ИЮНЬ Подготовка — найм, контракты, заготовки

2 FTE · ~1.5M P

- Найм CTO (full-time) + Sr Next.js dev (full-time). Опционально — 0.5 designer.
- Контракты: Anthropic ZDR, Cloudflare, Neon, ElevenLabs Pro, Render (для прокси). Telegram BotFather регистрация, MAX bot регистрация.
- Domain + WebApp registration в Tg, MAX. Sentry projects, Linear для задач.
- Скелет монорепо: app-mini (Next.js 16), api-edge (Hono), shared (Drizzle schema). Drizzle миграции в Neon.
- CI/CD: Cloudflare Pages + Workers, dev/preview/prod-окружения, automated PR-previews через Neon branching.

Gate выхода: **двое в команде, репо собирается, deploy «hello world» в Tg и MAX dev-аккаунты.**

M1-M2 · ИЮЛЬ-АВГ Beta 0 — мини-апп v0.1 для 1 000 кламперов

2 FTE · ~3M P

- 5 экранов прототипа в продакшен: Лента, Статья, Налоги, Сообщество, Профиль. Tg Mini App SDK 7.x, valid initData.
- Tiptap-CMS для редакции — без AI-агентов, ручной импорт. Drizzle-схема статей, авторов, реакций, сохранений.
- Базовый функционал: подписка на рубрики, утренний дайджест в 7:00, реакции, сохранения, push-нотификации.
- Hyperdrive для PG-кэша. R2 для аудио/обложек. CDN-imagery через Cloudflare Images.
- Закрытая бета: invite-link для региональных лидеров X10. **1 000 кламперов** через канал Рыбакова.

Gate выхода: **DAU/MAU ≥ 25%, 4-week retention ≥ 30%, NPS ≥ 40 на закрытой группе.**

M3-M4 · СЕНТ-ОКТ Beta 1 — AI-пайплайн контента + сторитемплейт

3 FTE · ~4M P

- +1 Sr React Native dev для M6+ нативки и shared компонентов.
- Анти-MVP AI: **3 агента из 6** — ToV-Agent (чёрный список), BrevityAgent (режет до 300 слов), AudioAgent (TTS ElevenLabs). DraftAgent в M5.
- KikuAI Masker как middleware. Helicone observability. Token-budget alerts.
- Второй шаблон статьи — **«Story / От первого лица»** (как редизайн Васильева): таймлайн, цитата-перелом, grid «что сейчас», 3 урока.
- Comments + reactions поверх Zero sync-engine. Локальный IndexedDB + WebSocket дельты.

Gate выхода: **110 статей/мес через пайплайн, AI-cost < \$80/мес, редактор экономит ≥ 30 мин на статью.**

M5-M6 · НОЯБ-ДЕК GA Public — MAX, e-mail, реферальная программа

4 FTE · ~5M P

- +1 ML/AI engineer (part-time): полный пайплайн из 6 агентов, prompt-caching оптимизация, web_search в NumbersAgent.
- **MAX Mini App запуск** через VK Platform Bridge, тот же кодовая база. Канал X10 Daily в MAX.
- E-mail-рассылка через Resend + React Email. Утренний дайджест в формате Morning Brew. Конверсия из e-mail в mini-app.
- Реферальная программа: 5 рефералов → мерч, 25 → invite на ивент, 100 → личный звонок региональному лидеру.
- Web-зеркало через Next.js 16 SSR для SEO. Каждая статья — URL /d/{slug}.
- Search через pgvector. ToV-чек-лист (15 пунктов) автоматически в Tiptap.

Gate выхода: **5 000 DAU, ≥ 5 рубрик, 4-week retention ≥ 35%, готовность к Premium-запуску.**

M7 → M12

Roadmap фаза 2 — монетизация и масштаб

Вторая половина года — превращение медиа в продукт с подпиской. Premium-paywall, кламповые чаты с sync-engine, «Спроси X10» RAG, B2B-выпуски, веб-зеркало для SEO, и в M12 — старт native iOS.

M7-M8 · ЯНВ-ФЕВ 2027 Premium — paywall, биллинг, эксклюзивная аналитика

4 FTE · ~5.5M ₽

- **X10 Premium 1500 ₽/мес** через Telegram Payments + ЮKassa + Tinkoff. Возврат, инвойсы, чеки 54-ФЗ.
- Gated-разделы: эксклюзивная аналитика Рыбакова, «Налоги Pro», полные расшифровки видео-разборов.
- Биометрический вход для Premium (Tg BiometricManager). Premium-бейджи в UI.
- Сегментация контента: разные «лестницы доступа» по типам подписки (free / trial / premium).
- Помесячная отчётность подписок: cohort retention, churn, MRR/ARR — в Grafana дашборде поверх Neon.

Gate выхода: **≥ 150 paid, churn ≤ 8%, payback ≤ 4 мес, gross margin ≥ 80%.**

M9 · МАРТ Кламповые чаты + «Спроси X10» RAG

5 FTE · ~6M ₽

- +1 DevOps/SRE (part-time): инфра-as-code (Terraform на Cloudflare + Neon), мониторинг, alerts.
- Кламповые чаты на **Zero sync engine** — local-first IndexedDB + per-clamp Durable Objects. AI-резюме треда внутри клампа («что обсуждали без меня»).
- **«Спроси X10»** — RAG-чат на pgvector + Sonnet 4.6. Ответы со ссылками на источники (контент Рыбакова, статьи Daily, видео-расшифровки).
- Календарь событий с GeolP-фильтрацией по городам, RSVP, синхронизация с Tg-календарём.

Gate выхода: **30% Premium используют RAG ≥ 3 раза/нед, latency p95 < 600 мс.**

M10 · АПРЕЛЬ DealExchange + авторские страницы

5 FTE · ~6M ₽

- **DealExchange MVP** (как у EO MyEO): board сделок между кламперами — продаю/покупаю/ищу партнёра. Модерация ручная.
- Авторские страницы для редколлегии (Stratechery / Lenny-style) — каждый журналист со своей лентой и подпиской. Подготовка к миграции редколлегии (Roadmap #5).
- Native iOS/Android через Expo + EAS. Тот же React-код. M12 — публикация в RuStore.

Gate выхода: **200+ deals в month, 3 авторских голоса рядом с Рыбаковым.**

M11-M12 · МАЙ-ИЮН B2B-выпуски + scale + сувенирная газета

5-6 FTE · ~6M ₽

- +1 jr dev: помощь старшим, рутинная поддержка, фиксы.
- **B2B-выпуски** (Morning Brew CFO Brew style): «X10 Налоги», «X10 HR», «X10 Стройка» — для отраслей внутри X10. Каждый — отдельная gated-рубрика.
- SEO-канонический веб-сайт для лонгридов. Sitemap, Open Graph, JSON-LD article schema.
- Ежеквартальная сувенирная печать газеты — для форумов КОД X10, Business Meet Up. Печать как артефакт, не канал.
- Финальная калибровка перформанс-бюджетов на полной нагрузке. Stress-test до 100K concurrent через k6.

Gate выхода M12: **24K DAU, 700 paid, ARR ~12M ₽, EBITDA-разрыв снижается, готовность к Series A (если решим).**

КОМАНДА

FTE ramp-up — кто нужен и когда, в человеко-зарплатах

Команда растёт по триггерам метрик, не по календарю. Стартуем с двоих (CTO + Sr dev), пик к M12 — шестеро инженерных + 0.5 designer. **ФОТ год = 17,4М Р**, включая 30% страховых поверх рынка — это совпадает с Base-сценарием финмодели.

РОЛЬ	СТАРТ	FTE	МЕСЯЧНАЯ GROSS	ЗОНА ОТВЕТСТВЕННОСТИ
CTO / Tech Lead	M0	1.0	400 000 Р	Архитектура, найм, code review, security, decision-making по стеку.
Sr Full-Stack (Next.js)	M0	1.0	280 000 Р	UI-shell мини-аппа, Hono API, Tiptap CMS, Drizzle, integration с Tg/MAX SDK.
Sr Mobile/RN dev	M3	1.0	270 000 Р	Mini App optimization, M10+ native iOS/Android через Expo. Shared компоненты.
ML / AI Engineer	M5	0.5 → 1.0 (M7)	250 000 Р	6 агентов пайплайна, prompt-engineering, RAG на pgvector, AI-cost optimization.
DevOps / SRE	M9	0.5	130 000 Р	Terraform, мониторинг, alerts, on-call, performance-аудиты.
Jr Full-Stack dev	M11	1.0	150 000 Р	Рутинная поддержка, баг-фиксы, мелкие фичи. Mentorship от CTO/Sr.
Product Designer	M2	0.5	150 000 Р	Figma-система, новые экраны, иллюстрации, иконки. Дополняет существующий ToV/Visual код.

Помесячный ramp-up FTE и ФОТ (с 30% страховыми)

МЕСЯЦ	M0	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12
Eng FTE	2.0	2.0	2.5	3.5	3.5	4.0	4.0	4.5	4.5	5.0	5.0	6.0	6.0
ФОТ · КР	884	884	1080	1431	1431	1593	1593	1755	1755	1924	1924	2119	2119

ИТОГО ЗА 12 МЕСЯЦЕВ

17,4М Р

ФОТ ИНЖЕНЕРНЫХ + 0.5 DESIGN (С 30% СТРАХОВЫМИ)

Соответствует Base-сценарию финмодели. **Стратегия v1.0** предполагала 4.5 FTE = ~13.5М Р; реальный ramp выше на ~30% по двум причинам: 1) честный учёт страховых, 2) +1 ML-инженер с M5 (стратегия его недооценила).

ПРИНЦИП НАЙМА

Каждый найм — gate, не календарь

Jr dev в M11 берём *если* к M10 видны бэклог-проблемы. ML engineer в M5 — *если* пайплайн на 3 агентах работает стабильно. DevOps в M9 — *если* ручной деплой ломается чаще раз/нед. **Триггеры в Linear, не в Excel.**

БЮДЖЕТ

Бюджет 12 месяцев — P&L разработки

Капексных нет — всё OpEx. **ФОТ ~92% бюджета**, инфра ~5%, AI ~1.6%, остальное — инструментарий. Цифры синхронизированы с финмоделью Base-сценария: общий OpEx года 30.5М Р, из них на разработку — **18.9М Р**, на редколлегию + маркетинг + ивенты + G&A — 11.6М Р.

КАТЕГОРИЯ	M0	M6	M12	ГОД · Р	КОММЕНТАРИЙ
ФОТ инженерные (gross+30%)	884K	1 593K	2 119K	17 441K	См. стр. 13 — ramp от 2 до 6 FTE.
Cloudflare Workers + Pages	2K	8K	25K	120K	Paid plan + per-request на пике.
Cloudflare Hyperdrive + R2 + KV	1K	5K	12K	60K	R2 без egress, основная плата за storage.
Neon Postgres (Frankfurt)	2K	15K	38K	230K	Scale-plan с M5, autoscale compute.
Yandex Cloud (фолбэк РФ)	3K	8K	15K	100K	Standby для GeoDNS-route.
Anthropic API (Claude)	2K	10K	25K	140K	6 агентов + персонализация + RAG.
ElevenLabs (TTS)	8K	15K	25K	220K	Pro план + voice cloning + symbols cap.
Resend (email)	2K	8K	25K	130K	До 100K писем/мес к M12.
Sentry + Helicone + Langfuse	3K	8K	12K	90K	Observability, error-tracking, LLM-логи.
Tools (Linear, Figma, GitHub, Vercel)	8K	12K	18K	160K	Pro-тарифы на команду 6 человек.
Render.com (ElevenLabs прокси + Masker)	4K	6K	8K	75K	Self-hosted PII Masker + WebSocket-bridge.
Domain, SSL, юридические	15K	2K	2K	60K	Регистрация доменов, ZDR-договор, NDA.
ИТОГО / месяц	934K	1 690K	2 324K	18 826K	ФОТ + инфра + AI + tools.

СВОДКА ПО СТРУКТУРЕ

92% бюджета — это люди, остальное — округление

ФОТ 17,4М Р = 92,4% · Инфра 0,7М Р = 3,7% · AI (Claude + Voyage + 11Labs) 0,36М Р = 1,9% · Tools + Email + прочее 0,38М Р = 2,0%. Это значит: **экономить можно только на найме.** Все технологические оптимизации (prompt caching, batch API, edge-кэш) — режут 5-8% от бюджета, не больше. **Цена ошибки в найме одного Sr-разработчика — больше всех годовых расходов на AI.**

SLA · DOD

Performance budgets – границы приёмки каждой фичи

Эти числа уходят в **Definition of Done** каждой задачи в Linear с первого спринта. Не «постараемся» — фича без укладки в бюджет не релизится. p98 — на дешёвом Android (Xiaomi Redmi 9, 2 GB RAM, 4G).

Core Web Vitals и психофизика (RUM p75)

МЕТРИКА	ЦЕЛЬ	ГРАНИЦА	ЧТО ЭТО ЗНАЧИТ НА ПРАКТИКЕ
LCP (Largest Contentful Paint)	≤ 1.8 с	≤ 2.5 с	Главное изображение/заголовок дайджеста виден за 1.8 с от тапа на иконку Mini App.
INP (Interaction to Next Paint)	≤ 150 мс	≤ 200 мс	P98 всех тапов и свайпов реагирует ≤ 200 мс. Доминирующая UX-метрика после марта 2024.
CLS (Cumulative Layout Shift)	≤ 0.05	≤ 0.1	Минимум вёрстки прыгает после загрузки. Все изображения с явным aspect-ratio.
TTFB (Time To First Byte)	≤ 150 мс	≤ 200 мс	Cloudflare edge POPs в Хельсинки/Стокгольме → 150 мс p95 для РФ. Yandex CF — 80 мс при фолбэке.
Mini App open	≤ 1.2 с	≤ 1.5 с	От тапа на бот-меню → первый кадр Mini App. Включает Tg WebView init.
JS bundle entry	≤ 150 KB	≤ 200 KB	gzipped, без heavy либ (video-player, charts) — те lazy-load после первого тапа.
Local mutation	≤ 12 мс	≤ 16 мс	Лайк, сохранение, реакция — мгновенно в UI через Zero queue. Сеть — отдельно.

AI / LLM ОТКЛИК		
TTFT streaming	≤ 500 мс	p95
Полный ответ агента	≤ 8 с	p95
Пайплайн 6 агентов	≤ 90 с	p95
«Спроси X10» (RAG)	≤ 600 мс	TTFT
AudioAgent (8 мин MP3)	≤ 45 с	генерация

ДОСТУПНОСТЬ И НАГРУЗКА		
Uptime SLA	99.5%	43 мин/мес error budget
Push delivery	≤ 5 с	от триггера до устройства
Stress-test target	100K	concurrent WebSocket
WebSocket latency	≤ 100 мс	broadcast в кламповом чате
DB connection pool	100%	Hyperdrive transaction-mode

DOHERTY THRESHOLD · 400 MC

Граница, ниже которой продуктивность резко растёт

IBM (Doherty/Thadhani, 1982) показали: когда отклик системы < 400 мс, пользовательская продуктивность **удваивается**. Выше — пользователь думает «о системе», ниже — «о задаче». Для X10 Daily это значит: **каждое взаимодействие быстрее 400 мс**. Это касается тапа, скролла, открытия статьи, лайка, поиска. Если что-то медленнее — это претензия на дизайн-ревью.

РИСКИ

Что может пойти не так — и что с этим делаем сейчас

Семь риск-кластеров с конкретными mitigation'ами. Внизу страницы — шесть стартовых решений, которые нужно принять **до начала М0**. Без них первый коммит делать рано.

РИСК	ВЕРОЯТНОСТЬ	МИТИГАЦИЯ
Блокировка Cloudflare в РФ	Средняя	Двойной стек с М0: Yandex Cloud Functions через GeoDNS-фолбэк. Стоимость 100K ₽/год, цена защиты — критическая.
152-ФЗ / Роскомнадзор	Низкая, но дорогая	KikuAI Masker middleware с первого вызова Anthropic. 0% ПДн в LLM. ZDR-контракт с Anthropic. Подробности в skill 152-fz-foreign-llm-compliance.
Vendor lock-in (Cloudflare, Neon, Anthropic)	Высокая, но не острая	Hono переносим на любой serverless. Drizzle абстрагирует Postgres. LiteLLM-проху для свапа LLM-провайдеров за 5 с.
Найм Sr-разработчика затянется	Высокая	Параллельный поиск через 3 канала: Habr/HH/X10-комьюнити. Готовность платить +20% к рынку. Контракт на испытательный без снижения качества.
Cold start: 0 → 24K DAU = переписка стека	Низкая	Стек с запасом ×3: Workers без cold start, Hyperdrive scaling, Neon autoscale. Stress-test до 100K concurrent в M12.
AI-агенты генерируют galimat'ю	Средняя	Human-in-loop архитектурно: publish API требует editor_id + approved_at. Helicone/Langfuse мониторинг качества output. Прогон на golden-set каждую неделю.
Бюджет превышает Base на +25%	Средняя	Ramp-up FTE по триггерам метрик, не календарю (стр. 13). Sentry billing alerts на инфра. Token-budget alerts в Helicone на AI.

Шесть решений, которые нужны до старта М0

- 01
- Двойной стек хостинга — Cloudflare Workers или Cloudflare + Yandex CF? Решение влияет на DevOps-нагрузку и cost-структуру. Рекомендация: **двойной с М0**, иначе блокировка убивает сервис в Q3-Q4.
- 02
- Регион Neon Postgres — Frankfurt (50 мс p95 до РФ, не санкционный) или Stockholm (40 мс, но риск санкций EU). Рекомендация: **Frankfurt**, со standby в Yandex для DR.
- 03
- Telegram Bot Token + WebApp domain — кто владелец? Игорь лично, юр.лицо X10, или X10 Daily LLC. Рекомендация: **отдельное юр.лицо** для развязки рисков и продажи в будущем.
- 04
- Anthropic ZDR-контракт — Zero Data Retention agreement подписать до первого вызова. Иначе input/output логируются 30 дней — это нарушение 152-ФЗ.
- 05
- Storybook + Figma → код — pipeline дизайн-системы. Рекомендация: Figma + Tokens Studio → Style Dictionary → Tailwind config. Каждый компонент в Storybook со snapshot-тестами.
- 06
- Редакционная CMS — Tiptap собственный или Sanity? Tiptap дешевле и кастомнее, Sanity быстрее. Рекомендация: **Tiptap** — нужна глубокая кастомизация под 6 AI-агентов с inline-diff.